




# *Ask My Thesis*

José Leitão

EDIT. Bootcamp: Deep Learning com TensorFlow

08 July, 2026

# Objective


**The goal of this project was to use a lightweight-deployment RAG system to create a more dynamic way of sharing the work I carried out in my master's dissertation.**

## Why?

- To have my dissertation featured in my portfolio
- A dissertation is always hard to present briefly
- To gain a deeper understanding of how to build a RAG system and the challenges involved




# Architecture



\*The models shown in this architecture are the defaults and can be changed in the YAML configuration file.

# Architecture




*\*The models shown in this architecture are the defaults and can be changed in the YAML configuration file.*


# Model Selection

## Key Characteristics:

- Strong performance across multiple languages (Portuguese and English)
- Lightweight and cost-efficient to run locally, simplifying deployment



# Data Preparation Pipeline



Appendix I

Appendix II & III

# Appendix I - Preprocessing

## 1. INTRODUÇÃO

Neste capítulo será realizado o enquadramento do projeto de dissertação, tendo em conta o contexto real do estudo, serão apresentados os objetivos do mesmo, a metodologia de investigação utilizada no desenvolvimento deste estudo e, por fim, a apresentação da estrutura geral deste documento.


### 1.1 Enquadramento

As empresas do setor de retalho alimentar oferecem uma grande variedade de produtos frescos, estes que, normalmente, representam cerca de 40% das receitas das cadeias deste setor. Tendo em conta isto e a constante evolução competitiva da área, o aparecimento de soluções cada vez mais inovadoras e os clientes cada vez mais exigentes, este setor tem apresentado cada vez mais preocupação com a eficácia e eficiência operacional dos seus processos (Cortés Rodríguez et al., 2023; Marques et al., 2022). Assim, a implementação de técnicas *Lean* tem vindo a ganhar relevância no setor de retalho e torna-se um passo imprescindível para atingir uma eficiência operacional de excelência.

De acordo com Jaca et al (2012), no setor do retalho, minimizar o desperdício envolve ações como fazer uma boa gestão de inventário, utilizar de forma mais eficiente o espaço da loja, tendo como foco produtos de valor mais elevado, melhorar a eficiência de transporte e logística, e prevenir o aparecimento de produtos defeituosos. No entanto, a disponibilidade de produto, definida como a probabilidade de ter um produto em *stock* quando um cliente chega, é provavelmente o indicador-chave de nível de serviço ao cliente no retalho (Calvo et al., 2023; Marques et al., 2022). Neste contexto, pode-se dizer que os

```
{
  "level": "chapter",
  "number": "1",
  "title": "INTRODUÇÃO",
  "chapter_number": "1",
  "chapter_title": "INTRODUÇÃO",
  "section_number": null,
  "section_title": null,
  "page_start": 20,
  "page_end": 20,
  "text": "Neste capítulo será realizado o enquadramento do projeto de dissertação,"
},
{
  "level": "section",
  "number": "1.1",
  "title": "Enquadramento",
  "chapter_number": "1",
  "chapter_title": "INTRODUÇÃO",
  "section_number": null,
  "section_title": null,
  "page_start": 20,
  "page_end": 21,
  "text": "As empresas do setor de retalho alimentar oferecem uma grande variedade,"
},
```


# Data Preparation Pipeline



Appendix I

Appendix II & III


# Data Preparation Pipeline




Appendix I

Appendix II & III

# Appendix II - Sections profiling




# Appendix III - Chunks profiling



**Nota:** Valores superiores a 500 devem-se apenas ao facto do título do capítulo ser adicionado ao texto como apoio para retrieval.

Em termos de corpo de texto não existem chunks superiores a 500.

# Data Preparation Pipeline



Appendix I

Appendix II & III

# Generation

## Two Operating Modes



**HF - Inference (API)**



**Ollama - Local**

## Setup

- Answers grounded exclusively in the provided context
- Responses in the same language as the question
- Explicit notice when the context does not contain the required information
- Custom error messages when using the API (e.g. rate limit exceeded, usage limit reached)

# Evaluation: Golden Dataset

A set of 123 question-answer pairs used to evaluate the system

| Field             | Description                                           |
|-------------------|-------------------------------------------------------|
| ID                | Unique identifier                                     |
| Question          | Question reflecting a realistic user need             |
| Relevant sections | List of relevant sections                             |
| Reference Answer  | Example answer used for evaluation via LLM-as-a-Judge |
| Language          | Language of the question (PT or EN)                   |
| Type              | answerable, unanswerable_on_topic or out_of_scope     |



# Evaluation: Golden Dataset

| Type                  | Count | Description                                       | Expected Behavior |
|-----------------------|-------|---------------------------------------------------|-------------------|
| answerable            | 73    | The answer is in the thesis                       | Answer            |
| unanswerable_on_topic | 23    | On-topic question, but not answered in the thesis | Refuse            |
| out_of_scope          | 27    | Off-topic question                                | Refuse            |

# Evaluation: Retrieval

Evaluates the quality of chunk retrieval

- Tests up to 10 retrieved chunks to find the optimal top-k
- Search types:
  - Similarity: semantic proximity
  - Maximal Marginal Relevance (MMR): balances relevance and diversity
- Evaluated metrics:
  - $\text{hit@k}$ : % of questions with at least one relevant chunk in the top-k
  - $\text{recall@k}$ : % of relevant chunks retrieved within the top-k
  - MRR: mean reciprocal rank of the first relevant result



# Evaluation: Generation

Evaluates the quality of the LLM's answers

→ LLM-as-a-Judge: Qwen2.5.14B

- **Check 1 (Refusal Rate):**

- Refusal rate for unanswerable and out-of-scope questions



- **Check 2 (Retrieval Distance):**

- Retrieval distance by question type

- **Check 3 (RAGAS):**

- Measures three metrics using RAGAS:

- Faithfulness: whether the answer is grounded in the retrieved context
- Answer Relevancy: how relevant the answer is to the question
- Semantic Similarity: similarity to the reference answer in the golden dataset



# Deployment

The system is currently deployed as a Streamlit app.

## AskMyThesis

Ask questions about the thesis, in Portuguese or English. Answers are grounded only in the document.

 Quem é o autor da dissertação?

 O autor da dissertação é José Luís Leitão de Matos.

> Sources (4 sections retrieved)

 Quais são os principais objetivos do projeto e que tipo de resultados se esperam alcançar?

 Os principais objetivos do projeto passam por melhorar a eficiência operacional e a ergonomia dos processos associados aos fluxos (receção, despicking, armazenamento e reposição) de várias famílias de produtos existentes nos vários supermercados MC. Espera-se obter resultados como aumento da eficiência e eficácia do fluxo de produtos desde a sua receção até à reposição na placa de vendas; redução de esforços ergonómicos relativos aos diferentes processos de logística interna; estudo de diferentes padrões de fluxo nas atividades de despicking, transporte e reposição.

> Sources (4 sections retrieved)

 What are the stages involved in building a discrete-event simulation model?


Ask about the thesis...




# Live Demo

- Quem é o autor da dissertação?
- Quais são os principais objetivos do projeto e que tipo de resultados se esperam alcançar?
- Que metodologia de investigação foi adotada e como se caracteriza?
- What are the stages involved in building a discrete-event simulation model?
- Qual é a fórmula química da água?

# Next Steps



- Develop a method for the LLM's answers to cite the sections where the information was found
- Evaluate results with other models and/or other LLM configurations (e.g. the impact of temperature and other sampling parameters)
- Analyze the performance gap with lighter LLMs to assess the cost-benefit trade-off
- Analyze the system's cost and latency



# *Ask My Thesis*

José Leitão

EDIT. Bootcamp: Deep Learning com TensorFlow

08 July, 2026