




Ask My Thesis

José Leitão

EDIT. Bootcamp: Deep Learning com TensorFlow

08 July, 2026

Objetivo


O objetivo deste trabalho foi desenvolver, através de um sistema RAG de deploy leve, uma forma mais dinâmica de partilhar o trabalho que desenvolvi na minha dissertação de mestrado

Porquê?


- Ter a dissertação presente no meu portefólio
- Uma dissertação é sempre algo difícil de apresentar de forma curta
- Perceber com maior profundidade como construir um sistema RAG e as suas dificuldades



Arquitetura



Arquitetura



Escolha dos modelos

Características:

- Bom desempenho em diferentes línguas (português e inglês)
- Leves e baratos para rodar localmente e facilitar deploy

Embedding

bge-m3-embedding



Generation

Qwen2.5-7B




LLM-as-a-Judge

Qwen2.5-14B



Pipeline Preparação de Dados



Anexo I

Anexo II e III

Anexo I - Preprocessing

1. INTRODUÇÃO

Neste capítulo será realizado o enquadramento do projeto de dissertação, tendo em conta o contexto real do estudo, serão apresentados os objetivos do mesmo, a metodologia de investigação utilizada no desenvolvimento deste estudo e, por fim, a apresentação da estrutura geral deste documento.


1.1 Enquadramento

As empresas do setor de retalho alimentar oferecem uma grande variedade de produtos frescos, estes que, normalmente, representam cerca de 40% das receitas das cadeias deste setor. Tendo em conta isto e a constante evolução competitiva da área, o aparecimento de soluções cada vez mais inovadoras e os clientes cada vez mais exigentes, este setor tem apresentado cada vez mais preocupação com a eficácia e eficiência operacional dos seus processos (Cortés Rodríguez et al., 2023; Marques et al., 2022). Assim, a implementação de técnicas *Lean* tem vindo a ganhar relevância no setor de retalho e torna-se um passo imprescindível para atingir uma eficiência operacional de excelência.

De acordo com Jaca et al (2012), no setor do retalho, minimizar o desperdício envolve ações como fazer uma boa gestão de inventário, utilizar de forma mais eficiente o espaço da loja, tendo como foco produtos de valor mais elevado, melhorar a eficiência de transporte e logística, e prevenir o aparecimento de produtos defeituosos. No entanto, a disponibilidade de produto, definida como a probabilidade de ter um produto em *stock* quando um cliente chega, é provavelmente o indicador-chave de nível de serviço ao cliente no retalho (Calvo et al., 2023; Marques et al., 2022). Neste contexto, pode-se dizer que os

```
{
  "level": "chapter",
  "number": "1",
  "title": "INTRODUÇÃO",
  "chapter_number": "1",
  "chapter_title": "INTRODUÇÃO",
  "section_number": null,
  "section_title": null,
  "page_start": 20,
  "page_end": 20,
  "text": "Neste capítulo será realizado o enquadramento do projeto de dissertação,"
},
{
  "level": "section",
  "number": "1.1",
  "title": "Enquadramento",
  "chapter_number": "1",
  "chapter_title": "INTRODUÇÃO",
  "section_number": null,
  "section_title": null,
  "page_start": 20,
  "page_end": 21,
  "text": "As empresas do setor de retalho alimentar oferecem uma grande variedade,"
},
```


Pipeline Preparação de Dados



Anexo I

Anexo II e III


Pipeline Preparação de Dados




Anexo I

Anexo II e III

Anexo II - Sections profiling




Anexo III - Chunks profiling



Nota: Valores superiores a 500 devem-se apenas ao facto do título do capítulo ser adicionado ao texto como apoio para retrieval.

Em termos de corpo de texto não existem chunks superiores a 500.

Pipeline Preparação de Dados



Anexo I

Anexo II e III

Generation

2 Modos de Funcionamento



HF - Inference (API)



Ollama - Local

Setup

- Responde apenas com contexto fornecido
- Responde na mesma língua da questão
- Explica que é impossível responder se o contexto não incluir o conteúdo pretendido
- No caso de utilizar a API, devolve mensagens personalizadas para erros (rate limit, hit usage limit, etc.)

Avaliação: Golden Dataset

Lista de 123 perguntas e respostas utilizadas para avaliar o sistema

Campo	Descrição
ID	Identificador
Pergunta	Pergunta que possa refletir as necessidades do utilizador
Secções relevantes	Lista de secções relevantes
Resposta de referência	Resposta exemplo, utilizada para avaliação através do LLM as Judge
Língua	Língua da questão (PT ou EN)
Tipo	answerable, unanswerable_on_topic ou out_of_scope



Avaliação: Golden Dataset

Tipo	Quantidade	Descrição	Ação
answerable	73	A resposta existe na tese	Responder
unanswerable_on_topic	23	Pergunta sobre o tema mas sem resposta na tese	Recursar
out_of_scope	27	Fora do tema	Recusar

Avaliação: Retrieval

Avalia qualidade de retrieval de chunks

- Testa até 10 chunks devolvidos, de forma a otimizar o top-k
- Tipos de pesquisa:
 - Similarity – proximidade
 - Maximum Marginal Relevance (MMR) – relevância/diversidade
- Métricas avaliadas:
 - hit@k – % de perguntas com pelo menos 1 chunk relevante no top-k
 - recall@k – % de chunks relevantes cobertas pelo top-k
 - MRR – posição do resultado mais relevante



Avaliação: Generation

Avalia qualidade de resposta do LLM

→ LLM-as-a-Judge: Qwen2.5.14B

- **Verificação 1 (Refusal Rate):**

- Taxa de recusa de questões sem resposta ou fora de tema



- **Verificação 2 (Retrieval Distance):**

- Distância de retrieval por tipo

- **Verificação 3 (RAGAS):**

- Mede três métricas através do RAGAS:

- Faithfulness: Se resposta é fiel ao contexto retrieved
- Answer Relevancy: Relevância da resposta para a pergunta
- Semantic Similarity: Semelhança com a resposta do golden set



Deployment

Atualmente o sistema está deployed através de uma app Streamlit

AskMyThesis

Ask questions about the thesis, in Portuguese or English. Answers are grounded only in the document.

 Quem é o autor da dissertação?

 O autor da dissertação é José Luís Leitão de Matos.

> Sources (4 sections retrieved)

 Quais são os principais objetivos do projeto e que tipo de resultados se esperam alcançar?

 Os principais objetivos do projeto passam por melhorar a eficiência operacional e a ergonomia dos processos associados aos fluxos (receção, despicking, armazenamento e reposição) de várias famílias de produtos existentes nos vários supermercados MC. Espera-se obter resultados como aumento da eficiência e eficácia do fluxo de produtos desde a sua receção até à reposição na placa de vendas; redução de esforços ergonómicos relativos aos diferentes processos de logística interna; estudo de diferentes padrões de fluxo nas atividades de despicking, transporte e reposição.

> Sources (4 sections retrieved)

 What are the stages involved in building a discrete-event simulation model?


Ask about the thesis...




Live Demo

- Quem é o autor da dissertação?
- Quais são os principais objetivos do projeto e que tipo de resultados se esperam alcançar?
- Que metodologia de investigação foi adotada e como se caracteriza?
- What are the stages involved in building a discrete-event simulation model?
- Qual é a fórmula química da água?

Próximos passos



- Desenvolver método para que a resposta do LLM seja acompanhada das secções em que o conteúdo se encontra
- Estudar resultados com outros modelos e/ou outras configurações do LLM (por exemplo, impacto do nível determinístico e “liberdade” configurada)
- Analisar gap de performance com LLMs mais leves, perceber custo/benefício
- Analisar custos e latência do sistema



Ask My Thesis

José Leitão

EDIT. Bootcamp: Deep Learning com TensorFlow

08 July, 2026